Programování se sdílenou pamětí Úvod do OpenMP a smyčky for AVS – Architektury výpočetních systémů Týden 7, 2024/2025

Jirka Jaroš

Vysoké učení technické v Brně, Fakulta informačních technologií Božetěchova 1/2, 612 66 Brno - Královo Pole jarosjir@fit.vutbr.cz



Paralelní programovací modely (abstrakce)



- Tři paralelní programovací modely
 - Abstrakce předkládané programátorovi
 - Ovlivňují jak programátoři přemýšlejí při psaní programů
- Tři architektury strojů
 - Abstrakce hardware pro software na nízké úrovni
 - Typicky odpovídají implementaci

1. Sdílený adresový prostor (Shared Address Space, SAS)

(MIMD, SPMD)

2. Zasílání zpráv (Message Passing, MP) (MIMD, SPMD)

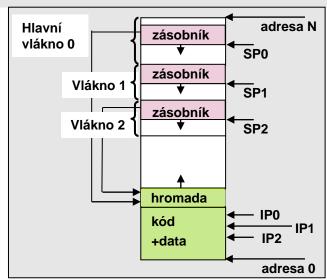
3. Datově-paralelní model

(SIMD, SIMT)

Sdílený adresový prostor (SAS)

T FIT

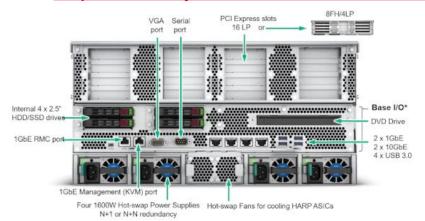
- Vlákna komunikují:
 - o čtením/zápisem do sdílených proměnných
 - Komunikace je implicitní v paměťových operacích snadnější programování.
 - Vlákno 1 zapíše do X, vlákno 2 čte X (vidí update).
 - To vyžaduje synchronizaci.
 - manipulací synchronizačních primitiv
 - např. vzájemné vyloučení použitím zámků
- Přirozené rozšíření sekvenčního programovacího modelu
- Sdílené proměnné jako velká nástěnka
 - každé vlákno může číst nebo zapisovat
 - problém se současným přístupem R+W ke sdíleným datům

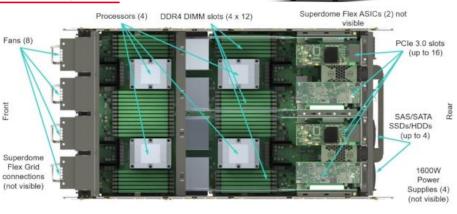




I Příklad špičkového systému se sdílenou pamětí NUMA I TEIT

- HPE Superdome Flex server
- 32x Intel® Xeon® Platinum, 24-core, 2.9 GHz, 205W
- 24 TB DDR4 2993MT/s of physical memory per node
- 2x 200 Gb/s IB port
- 71.2704 TFLOP/s
- https://www.youtube.com/watch?v=a6XBOCQfcF4





I Možnosti zápisu paralelních programů



- 1. Sekvenční jazyk + příkazy paralelního zpracování, komunikace a synchronizace (např. Universal Parallel C)
- 2. Sekvenční jazyk + dynamické knihovny:
 - programování s vlákny (Pthreads, Java threads, WindowsThreads ..., Intel Threading Building Blocks)
 - o nebo zasílání zpráv MPI (Message Passing Interface)
- 3. Sekvenční jazyk + direktivy pro kompilátor (pragma).
 - Umožňuje sekvenční i paralelní zpracování a inkrementální postup při paralelizaci
- 4. OpenMP API: kombinace direktiv a knihovních programů.

Výpočetní model vláken



Vlákna jsou ovládaná a použitá kernelem OS

- Uživatel má k dispozici knihovny vláken, např. POSIX threads, Windows threads.
- nebo API (**OpenMP**, OpenACC, CUDA, OpenCL).
- OS mapuje (plánuje) SW vlákna na HW vlákna.

HW vlákno

- Prostředky provádějící vlákno nezávislé na jiných HW vláknech.
- Vlákna 1 procesu mohou běžet na různých jádrech.
- Volání systému nebo knihovních programů musí být pro vlákna bezpečné (thread-safe), tj. správnost je zajištěna i při volání z více vláken současně.

Open Multi-Processing (OpenMP) API



- Vyvinuto konsorciem (OpenMP ABR) hlavních výrobců HW a SW pro paralelní výpočty se sdílenou pamětí (procesory i akcelerátory)
- Existuje API pro C/C++ a pro Fortran
 - První verze v roce 1997.
 - Současná verze 5.0 (2018).
 - Verze 5.2 ve stádiu implementace.
- Anglické tutoriály:
 - OpenMP 3.0:
 - https://computing.llnl.gov/tutorials/openMP/
 - o OpenMP 4.0:
 - http://wiki.scinethpc.ca/wiki/images/9/9b/Ds-openmp.pdf
 - Kompletní dokumentace 5.x, poslední vývoj, user's group:
 - http://www.openmp.org/specifications/
 - http://compunity.org



OpenMP API



OpenMP podporuje:

- o jemný a hrubý paralelismus (smyčky, paralelní sekce)
- datový a funkční paralelismus (SPMD, paralelní sekce)

OpenMP dovoluje:

- inkrementální paralelizaci programů se sdílenou pamětí
- psát přenosné a částečně škálovatelné programy
- psát paralelní programy se zabudovanou sekvenční verzí
- ověřit správnost programů

OpenMP zjednodušuje:

- psaní vícevláknových programů ve Fortranu, C a C++
- o ve verzi 4.0 existuje přidává vektorizaci SIMD (AVX)
- o dverze 4.0 podporuje programování akcelerátorů (Xeon Phi, GPU)

I Implementace OpenMP a kompilace

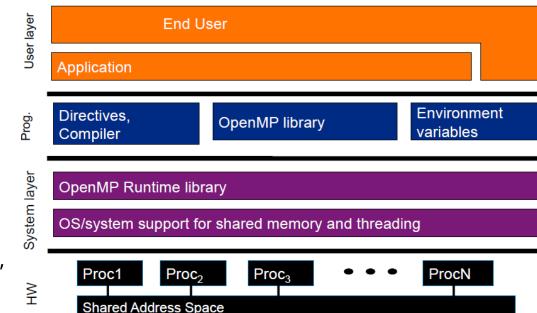


- Vlákna OpenMP jsou abstrakcí
 - implementace je může mapovat na vlákna kernelu OS, lehká vlákna POSIX (P-threads), Win32* threads apod.
- OpenMP je nezávislé na stroji a OS
 - přenos správného programu jinam vyžaduje "jen" rekompilaci
 - OpenMP-kompatibilní (-aware, -compliant) kompilátory existují pro všechny hlavní verze Unixu, Linuxu, Windows
 - Zapnutí OpenMP (gcc –fopenmp, intel –qopenmp)
- Implementace OpenMP pro C/C++ poskytují hlavičkový soubor soubor omp.h
 - s definicemi a prototypy funkcí.

I Tři součásti OpenMP



- Direktivy pro kompilátor
 - o #pragma omp ...
 - vytvoření týmu vláken
 - sdílení práce mezi vlákny
 - synchronizace vláken
- Knihovní rutiny
 - pro nastavení atributů vláken a dotazy na ně
 - omp_set_num_threads(...),
 - omp_get_thread_num(),
 - omp get num threads(),...
- · Proměnné prostředí
 - o řízení chování paralelního programu za jeho běhu (OMP_NUM_THREADS, OMP PLACES, OMP PROC BIND, OMP ENV DISPLAY, ...)
 - https://www.openmp.org/wp-content/uploads/OpenMP-4.5-1115-CPP-web.pdf



Model zpracování vláken: klíčové body



Vlákno

- IP + SP, registry, privátní zásobník.
- Na svou identitu se může dotázat.
- Je-li více vláken než logických jader (oversubscription)
 - o Pak se vlákna mapují na jádra dynamicky (Web servery).
 - Lépe 1 vlákno na 1 (logické) jádro, a staticky bindovat. Odpadá pak režie plánování vláken, vyplachování cache a další problémy.

Program OpenMP

- Se začne vykonávat jedním (hlavním) vláknem (master thread).
- Jakmile dojde k paralelnímu příkazu, vytvoří se tým vláken (worker threads).
- o Členové týmu provádějí příkazy paralelně a synchronizují se na bariéře.
- Program se může při běhu takto větvit a zase spojit mnohokrát (model fork–join).

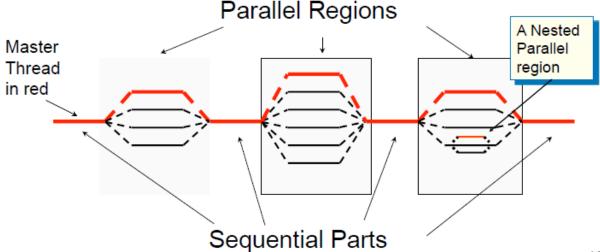
Model zpracování vláken



Strukturovaný blok:

- o blok jednoho nebo { více příkazů; } s jedním vstupem nahoře a jedním výstupem dole.
- Může obsahovat exit() uvnitř.

 Každá OpenMP direktiva platí pouze pro následující strukturovaný blok.



Direktivy kompilátoru

VYTVOŘENÍ TÝMU VLÁKEN

Vytvoření týmu vláken: direktiva parallel



Direktiva parallel

- o definuje paralelní oblast (region)
- vytvoří tým vláken
- o zahájí paralelní zpracování
 - strukturovaný blok provádějí všechna vlákna, každé vlákno specificky podle svého ID (→ SPMD)
- hlavní (master) vlákno má číslo 0
- na konci paralelní oblasti je automaticky bariéra

nastavení počtu vláken

```
01  omp_set_num_threads(4);
02  double a[1000];
03  #pragma omp parallel [clause[clause]...]
04  {
05    int id = omp_get_thread_num();
06    work(id, a);
07  }
Strukturovaný blok
vykonávaný 4 vlákny
```

I Dovětky (clauses) k direktivě parallel



```
private(list)
shared(list)
default(shared|none)
reduction(operator:list)
if(logical expression)
copyin(list)
num_threads(thread_count)
```

- Proměnné deklarované před paralelní oblastí musí být v jejím lexikálním (textovém) rozsahu označeny private nebo shared
 - bez označení budou shared (pozor na hazardy -> vzájemné vyloučení)
- if: vytvoření týmu vláken lze podmínit
 - o podle výsledku nějakého testu uživatele (např. počet iterací), se pracuje sekvenčně if (FALSE) nebo paralelně if (TRUE)

I Kolik vláken je v paralelní oblasti?



Počet je určen následujícími faktory, pořadí podle priority:

- Vyhodnocení dovětku if (jestli vůbec paralelně).
- Nastavení dovětkem num_threads (thread_count) v dané paralelní oblasti.
- Použitím knihovní funkce omp_set_num_threads (int) pro všechny následující paralelní oblasti.
- Nastavením proměnné prostředí pro celý program export OMP_NUM_THREADS=12
- Implementační implicitní hodnota = obvykle počet CPU (v tomto počtu jsou tvořena i "dynamická" vlákna).
- Počet vláken v týmu zůstává uvnitř paralelní oblasti konstantní. Pro další oblast jej může změnit:
 - uživatel(void omp_set_num_threads(int))
 - obslužný systém (dynamická vlákna)

I Chování privátních proměnných



- Dovětek private (var)
 - Vytvoří novou lokální kopii proměnné var pro každé vlákno
 - Hodnoty privátních proměnných nejsou v paralelní oblasti inicializovány na hodnotu původní sdílené proměnné var (C++ volá defaultní constructor)
 - Pokud potřebujeme okopírovat původní hodnotu do lokálních proměnných (C++ copy constructor), použijeme direktivu firstprivate
 - Za paralelní oblastí nejsou privátní proměnné dostupné obnoví se hodnota původní vnější proměnné před paralelní oblastí
 - Pokud potřebujeme přenést hodnotu privátních proměnných zpět do původní, můžeme využít buď reduction nebo lastprivate
- Privatizovat se mohou jen úplné objekty, nikoliv prvky polí nebo části datových struktur.
- Proměnné deklarované uvnitř paralelní oblasti jsou také privátní (bez dovětku)!
 AVS Týden 7: Úvod do OpenMP a smyčky for

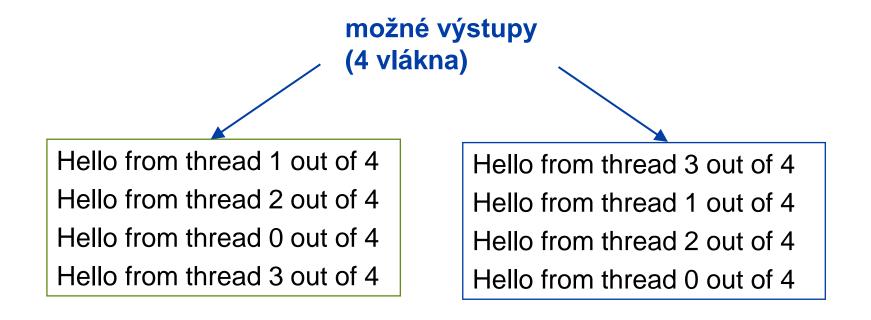
Multivláknový program Hello World v OpenMP



```
01 #include <omp.h>
02 #include <stdio.h>
                                     Direktiva paralelní oblasti,
03 void main(){
                                       počet vláken implicitní
04
     int tid, nt;
     #pragma omp parallel private(tid, nt)
05
06
                   Kolik nás je v týmu?
07
          omp get num threads();
                                                  Tento strukturovaný
08
       tid = omp get thread num();
                                                  blok provádí každé
09
                    Moje ID
                                                  vlákno! (SPMD)
10
       printf("Hello from thread %d \
             out of %d \n'', tid, nt);
                 Konec paralelní oblasti
11
12
```

Výstup Hello World v OpenMP





Vlákna vypisují v náhodném pořadí, tak jak dospěly k funkci printf.

Příklad: Privátní proměnné



```
int x = 5, y = 6, z = 7;
float a[10], b[10], c[10];
#pragma omp parallel num threads(5) \
       private(x, a)
       firstprivate(y, b)
       shared(z, c)
 int thread id = omp get thread num();
                                       Co bude v proměnných?
 x++; y++; z++;
 a[thread id] = 0;
                                       Kam zapíši?
 b[thread id] = 1;
 c[thread id] = 2;
 a += thread id; *a = 5;
                                       Kam zapíši?
 b += thread id; *b = 5;
 c += thread id; *c = 5;
```

I Interpretace direktiv a podmíněná kompilace



Program v OpenMP v sobě může mít zabudovánu sekvenční verzi:

```
Kompilátor s OpenMP
#pragma omp
se bere jako direktiva OpenMP
#ifdef OPENMP
 příkazy, které se mají
 provést jen v paralelní
 verzi (např. knih. fce)
#endif
```

```
Kompilátor bez OpenMP
#pragma omp
pragma je ignorováno
#ifdef OPENMP
 tyto příkazy se v sekvenční
 verzi vynechají
#endif
```

Makro OPENMP = yyyymm = rok a měsíc schválené specifikace OpenMP.

Paralelní Hello World se sekvenční verzí



```
#include <stdio.h>
#ifdef OPENMP
      #include <omp.h>
#endif
void main() {
    int tid = 0, nt = 1;
    #pragma omp parallel private(tid, nt)
             OPENMP
      #ifdef
        nt = omp get num threads();
        tid = omp get thread num();
      #endif
      printf("Hello from thread %d out of %d \n", iam, nt);
```

Rozsah platnosti direktiv



- Direktivy platí pouze v jejich statickém, tj. lexikálním rozsahu
 - Statický nebo lexikální rozsah: kód textově uzavřen mezi začátek a konec strukturovaného bloku následujícího za direktivou
 - Dynamický rozsah: statický rozsah rozšířený o procedury a funkce volané zevnitř statického rozsahu
 - Direktiva, která je v dynam. rozsahu jiné direktivy, ale ne v jejím statickém rozsahu, se nazývá sirotek (orphan).

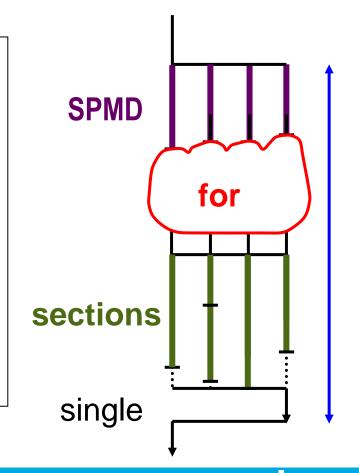
```
#pragma omp parallel
{
   void dowork();
}
```

```
void dowork ()
{
    #pragma omp for
    for (int i=0; ...)
    ...
}
```

I SPMD a sdílení práce v paralelní oblasti



- Direktiva parallel sama o sobě představuje program SPMD, tj. každé vlákno provádí redundantně stejný kód.
- Jak diverzifikovat práci vláken v týmu?
 Pomocí direktiv uvnitř paralelní oblasti pro sdílení práce (work sharing):
 - ve smyčce for
 - v sekcích
 - 1 vláknem (single)
 - v úlohách (task)



Direktivy kompilátoru

PARALELIZACE SMYČEK

Smyčka for – motivační příklad



Sekvenční kód

OpenMP, jen direktiva parallel

OpenMP,
Direktiva parallel a for

```
for(i=0;i< N;i++) { a[i] = a[i] + b[i];}
```

```
#pragma omp parallel
        int id, i, Nthrds, istart, iend;
        id = omp get thread num();
        Nthrds = omp get num threads();
        istart = id * N / Nthrds;
        iend = (id+1) * N / Nthrds;
        if (id == Nthrds-1)iend = N;
        for(i=istart;i<iend;i++) { a[i] = a[i] + b[i];}
```

```
#pragma omp parallel
#pragma omp for
for(i=0;i<N;i++) { a[i] = a[i] + b[i];}</pre>
```

Paralelizace smyček: tým vláken si rozdělí iterace ve smyčce for



- počet iterací musí být znám na vstupu do smyčky
- všechny iterace se musí dokončit, blok: 1 vstup, 1 výstup
- schedule kind: static, dynamic, guided, runtime, auto
 - Norma OpenMP 4.5 zavádí modifikátor chunku simd, monothonic, nonmonothonic.
 Např. schedule (simd:static)
- vnořené smyčky:
 - o paralelně se dělá jen smyčka nejbližší direktivě
 - o její index je implicitně privátní

Vnořené smyčky

```
#pragma omp parallel for
for (int y = 0; y < 25; ++y)
 #pragma omp for
  for (int x=0; x < 80; ++x)
   tick(x,y);
#pragma omp parallel for collapse(2)
for (int y = 0; y < 25; ++y)
  for (int x = 0; x < 80; ++x)
   tick(x,y);
```

vnoření paralelních smyček je nelegální

> novější dovětek **collapse** vytvoří jednu smyčku ze 2 vnořených a tu paralelizuje.

Pozor: Zavádí režii výpočtu indexů *x a y*

Zkrácené zápisy dvojice direktiv



Tyto zápisy jsou ekvivalentní:

```
double res[MAX]; int i;
#pragma omp parallel
{
    #pragma omp for
    for (i = 0; i < MAX; i++)
        res[i] = huge();
}</pre>
```

```
double res[MAX]; int i;
#pragma omp parallel for
for (i = 0; i < MAX; i++)
  res[i] = huge();</pre>
```

když paralelní oblast obsahuje jen #pragma omp for

Podobně lze zkrátit #pragma omp parallel sections

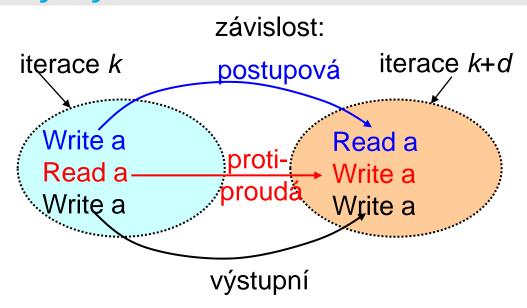
Příklad: matice b($n \times m$) krát vektor c($n \times 1$) = vektor a($n \times 1$)



```
void mxv(int n, int m, double* a, double* b[],
            double* c)
 #pragma omp parallel for default(none) \
          shared(m,n,a,b,c)
                                        paralelní smyčka
 for (int i=0; i < n; i++)
                                        sekvenční smyčka
  double sum = 0.0;
  for (int j=0; j < m; j++)
     sum += b[i][j]*c[j];
  a[i] = sum;
                                                       *
Bude-li n = 10 řádků a 2 vlákna,
pak thread 0 si vezme řádky i = <0, 4>
a thread 1 řádky i = <5, 9>.
```

I Pozor: smyčky se závislostmi mezi iteracemi





- Neznáme pořadí provedení iterací!
 - Iteraci k provádí jedno vlákno v čase t, ale iteraci k+d může provádět jiné vlákno před nebo po iteraci k (nejisté!)
 - o Kompilátory OpenMP nekontrolují závislosti mezi iteracemi.
 - Když výsledek iterace závisí na jiných iteracích, nelze přímo paralelizovat.

I Paralelizace smyček se závislostmi



Jak udělat iterace smyčky nezávislé, aby mohly být prováděny v libovolném pořadí bez závislostí?

Příklad:

```
for (i=2; i<=m; i++)
  for (j=1; j<=n; j++)
a[i][j] = 2 * a[i-1][j];</pre>
Závislost v indexu i přemístíme do sekvenční smyčky, tam nevadí:
int i, j;
#pragma parallel for private(i)
for (j=1; j \le n; j++) \leftarrow paralelní, j je impl. privátní
 for (i=2; i \le m; i++) \leftarrow sekvenční, i je privátní
  a[i][j] = 2 * a[i-1][j];
```

Pozor ale na lokalitu dat!

I Dovětek reduction



- reduction (op: list) provádí redukci skalárních proměnných na seznamu list, operátorem op
- je vytvořena privátní kopie každé proměnné ze seznamu list (jedna pro každé vlákno) a inicializována.
- Na konci je atomicky aktualizována každým vláknem stejnojmenná sdílená proměnná.

I Operátory a inicializace redukčních proměnných



Operátor	Poč. hodnota	Operátor	Poč. hodnota
+	0	&	~0
*	1		0
-	0	٨	0
min	max. možná	&&	1
max	min. možná		0

OpenMP 4.0:

 Rozšíření o redukce definované uživatelem #pragma omp declare reduction ...

I Příklad redukce



```
int mini = a[0];
int maxi = a[0];
for (i=1; i<n; i++)
  if (a[i] < mini)
   mini = a[i];
  if (a[i] > maxi)
   maxi = a[i];
int mini, maxi;
# pragma omp parallel for reduction \
          (min:mini, max:maxi)
```

OpenMP smyčky

PLÁNOVÁNÍ ITERACÍ

Statické plánování iterací



```
#pragma omp for schedule(static[, chunk_size])
for (i=0; i<n; i++) {
  the_same_work(i);
}</pre>
```

- nejméně režie při běhu, naplánování provedeno v době kompilace.
- když není udán chunk_size, dostane každé vlákno cca stejnou porci iterací q.
 - Je-li n = t * q r, pak některá vlákna dostanou méně než q (r-krát q - 1 nebo 1 krát q - r)
- je-li udán chunk_size, jsou porce přiděleny vláknům cyklicky (prokládané plánování). Užitečné, když se práce v iteracích mění lineárně.
- Jeli udán modifikátor SIMD, je chunk_size zarovnán na velikost SIMD registru.

Statické plánování iterací

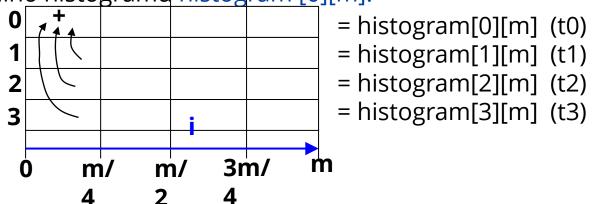


```
#pragma omp for schedule(static[, chunk size])
  for (i=0; i < n; i++) {
      the same work(i);
                                                   chunk
               4 vlákna bez chunk
Příklad: 16 iterací, 4 vlákna:
   Thread ID
   no chunk
                0–3
                           4–7
                                      8–11
                                                 12–15
   chunk=2
                0-1
                           2–3
                                      4–5
                                                 6–7
                           10-11
                                     12-13
                8-9
                                                 14–15
```

Příklad výpočtu histogram



- Vektor a[n] má prvky integer v intervalu <0, m-1>. Četnost výskytu různých hodnot se má znázornit histogramem histogram[m].
 - Nejdřív každé z P vláken vytvoří vlastní histogram histogram[myid][m], myid = 0, ..., nt-1 ze svého segmentu vektoru a[n]
 - o pak každé vlákno posčítá jednu část všech *P* histogramů do části jednoho globálního histogramų histogram [0][m].



Příklad: histogram hodnot prvků vektoru a[n]



```
// až 10 vláken
int histogram [10][m];
#pragma omp parallel shared (a, m, n)
  int nt, myid, i, k;
 nt = omp get num threads();
 myid = omp get thread num();
  #pragma omp for schedule(static) num threads(10)
  for (i = 0; i < n; i++)  // segmenty vektoru</pre>
    histogram[myid][a[i]]+=1;
  #pragma omp for schedule(static) num threads(2)
  for (i = 0; i < m; i++) { // segmenty histogramů
    for (k = 1; k < nt; k++) // vláken k > 0 do k = 0
      histogram[0][i]+=histogram[k][i];
```

I Dynamické plánování iterací



```
#pragma omp for schedule(dynamic[, chunk_size])
  for (i = 0; i < n; i++) {
    unpredictable_amount_of_work(i);
}</pre>
```

- iterace jsou přidělovány po blocích (chunk_size ≥ 1), se synchronizací (exkluzivním přístupu k indexu) při každém přidělení → největší režie za běhu
- default chunk_size = 1; čím je chunk_size větší, tím je menší synchronizační režie ale hrubší vyvážení zátěže.
- vlákno čeká na bariéře nejvýš dobu kterou trvá jinému vláknu dokončit jeho posledních chunk_size iterací.

I Řízené (guided) plánování iterací



```
#pragma omp for schedule(guided[, chunk_size])
  for (i = 0; i < n; i++) {
    the_similar_work(i)
  }</pre>
```

- menší synchronizační režie než dynamic;
- typická implementace přidělí prvnímu volnému vláknu porci q₀ = \[\text{n} / t \] iterací
- následující porce se přidělují podle vztahu
 q_i = \[q_{i-1}(1 1 / t) \]
 (minimálně chunk_size, default chunk_size je 1);
- pro další iterace jde vlákno, které právě dokončí předchozí porci iterací.

I Řízené plánování, příklad 4 vlákna = 4 barvy



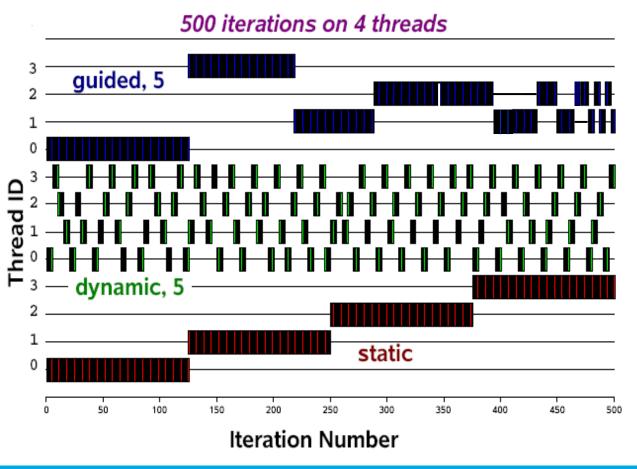
Příklad: 200 iterací. Postupně odebrané porce: 50 = [200 / 4)],**38** = [50(1 - 1/4)]**29** = [38(1 - 1/4)]. 22 = $\lceil 29(1-1/4) \rceil$, vlákno skončilo 1. porci iterací, 17, ... dostane 2. porci 13, vlákno přichází pro 2. porci, 10, ... vlákno přichází pro 2. porci, 8, ... vlákno přichází pro 3. porci, 6, ... atd. 5,

2.

Celkem iterací na vlákna: 50, 50, 48, 52 a 11 synchronizovaných přístupů k indexu smyčky

I Porovnání průběhů smyček





I Příklad: rozvržení iterací na vlákna



 Mějme 35 stejně náročných iterací 0 až 34, 3 vlákna 0 až 2. Najděte všechny dávky iterací přidělené vláknům 0–2.

	vlákno 0	vlákno 1	vlákno 2
static, no chunk	12	11	11
static, chunk = 5	5 + 5 + 4	5 + 5	5 + 5
dynamic, chunk = 7	7 + 7	7 +6	7
guided, no chunk	12	8 + 3	6 + 4 + 1

I Plánování iterací pro 1 běh programu a auto



#pragma omp for schedule(runtime)

 Způsob plánování (schedule kind) a chunk_size mohou být zvoleny pomocí proměnné prostředí OMP_SCHEDULE před provedením programu, např. v Unixu příkazem shellu

```
setenv OMP_SCHEDULE "dynamic,3"
```

To je pohodlné pro experimentování, není nutná rekompilace.

#pragma omp for schedule(auto)

 Plánování je ponecháno na obslužném (runtime) systému. Vhodné, když se obslužný systém může učit z předchozích běhů téže smyčky.

I Jak naplánovat přidělení iterací vláknům



- schedule(static) má nejmenší režii
 - vhodné, když je práce v iteracích stejná (bez chunk_size) nebo se mění lineárně (pak je chunk_size nutný).
- schedule(dynamic, chunk_size) je vhodná pro vyvážení zátěže, když provedení iterací trvá různě dlouhou dobu
 - bez chunk_size je sync. režie příliš velká (implicitně chunk_size = 1)!
- schedule (guided) je vhodná pro iterace s ne příliš rozdílnou dobou provedení
 - má nižší počet porcí a tím nižší synchronizační režii než dynamic.

Modifikátory plánování smyček (OpenMP 4.0+)



simd – schedule(simd:static)

Velikost chunku se vždy zaokrouhlí na nejbližší vyšší velikost simdlen.

```
int dot;
#pragma omp parallel for simd \
   schedule(simd:static:100) reduction(+: dot) aligned(a, b: 64)

{
   for (int i = 0; i < N; i++)
      dot += (a[i] * b[i]);
}</pre>
```

monotonic – schedule(monotonic:dynamic)

- Pokud již vlákno vykonalo iterací i, musí být následující iterace větší než i (monotónně rostoucí posloupnost)
- nonmonotonic schedule(nonmonotonic:dynamic)
 - Iterace se mohou přidělovat v libovolném pořadí

I Dovětek nowait



```
#pragma omp parallel default(none) \
        shared(n, a, b, c, d) private(i)
 #pragma omp for nowait
  for (i = 0; i < n-1; x++)
                                          Zrušena
   b[i] = (a[i] + [a[i+1]) / 2;
                                          implicitní
                                          bariera
 #pragma omp for nowait
  for (i = 0; i < n; y++)
    d[i] = 1.0 / c[i];
```

OpenMP

IMPLICITNÍ CHOVÁNÍ PROMĚNNÝCH

I Implicitní chování proměnných v C/C++



- Proměnné deklarované/použité před příkazem parallel jsou v paralelní oblasti implicitně sdílené.
 - např. indexové proměnné sekvenčních smyček musí být v dovětku označeny jako privátní.
 - indexové proměnné paralelních smyček nemusí být na seznamu v dovětku private (), jsou implicitně privátní.
- Automatické proměnné deklarované v bloku příkazů uvnitř paralelní oblasti nebo lokální proměnné ve funkcích volaných z paralelní oblasti jsou privátní (na zásobníku).
 - Proměnné static jsou sdílené, a jsou staticky alokovány kompilátorem v předurčené oblasti sdílené paměti.

I Příklad sdílených a privátních dat

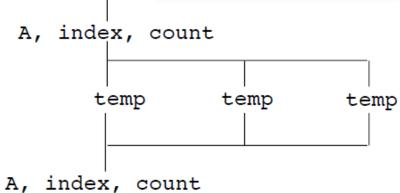


```
extern double A[10];
void work(int * index)
{
  double temp[10];
  static int count;
}
```

A, index a **count** jsou **sdílené** všemi vlákny.

temp je lokální (privátní) v každém vláknu.

```
double A[10];
int main(){
  int index[10];
  #pragma omp parallel
    work(index);
  printf("%d\n", index[0]);
}
```



I Chování firstprivate and lastprivate proměnných



- **firstprivate** (list)... pro inicializaci stejnojmenných privátních proměnných všech vláken ve smyčce jsou použity původní hodnoty proměnné hlavního vlákna 0 (konstrukce C++ copy konstruktorem).
- lastprivate (list) ... hodnota privátní proměnné patřící vláknu, které provedlo poslední sekvenční iteraci (resp. sekci označenou jako poslední) je přiřazena kopii proměnné vlákna 0.
- proměnná může být případně jak firstprivate, tak lastprivate.
- když je použit default (none), musí být každá proměnná v některém seznamu (list) shared, first/last/private.
 - Výhodné pro debug kódu.

I Příklad



```
main() {
int C, B; int A = 20, n = 100, idx, *data;
... // alokace a načtení vektoru data
#pragma omp parallel
  #pragma omp for firstprivate(A) \
                       lastprivate(B,idx)
  for (int \frac{1}{4} = 0; i < n; i++) {
       B = A^{\dagger} + i; /* A: je-li jen private, není def. */
if (data[i] == 0) idx = i;
            /* B: je-li jen private, není hodnota B a tedy C def. */
             /* sdílené C = lastprivate B = 20 + n - 1 */
```

/* konec paralelní oblasti: idx je náhodně nastaveno některými vlákny v některých iteracích. Lastprivate je zde nesmysl, lépe je použít redukci (např. když hledáme nejvyšší index nulového prvku ve vektoru data). */

I Proměnné Threadprivate



- Globální proměnné, které mají být privátní pro každé vlákno v rámci celého programu, bez ohledu na lexikální rozsah direktivy parallel, lze definovat pomocí: #pragma omp threadprivate (list)
- Threadprivate proměnné všech vláken mohou být inicializovány na začátku paralelní oblasti hodnotami hlavního vlákna pomocí copyin (list) nebo v době jejich definice.

Pokračování příště